Universidade Federal da Paraíba

Arthur Vieira

Augusto Miguel

Carlos Eduardo

Igor Wanderley

Joás Gomes

Kalil Teotonio

PROJETO DE ENGENHARIA DE SISTEMAS DISTRIBUÍDOS

DOCUMENTO ARQUITETURAL

João Pessoa, PB

2026

1. Diagramas de contexto e containers..... 2
2. Diagrama C4..... 3
3. ADRs iniciais..... 3
4. Definição de stack tecnológico e justificativas.....4
5. Identificação dos padrões arquiteturais..... 5
6. Divisão de responsabilidades entre os integrantes..... 6

1. Diagramas de contexto e containers

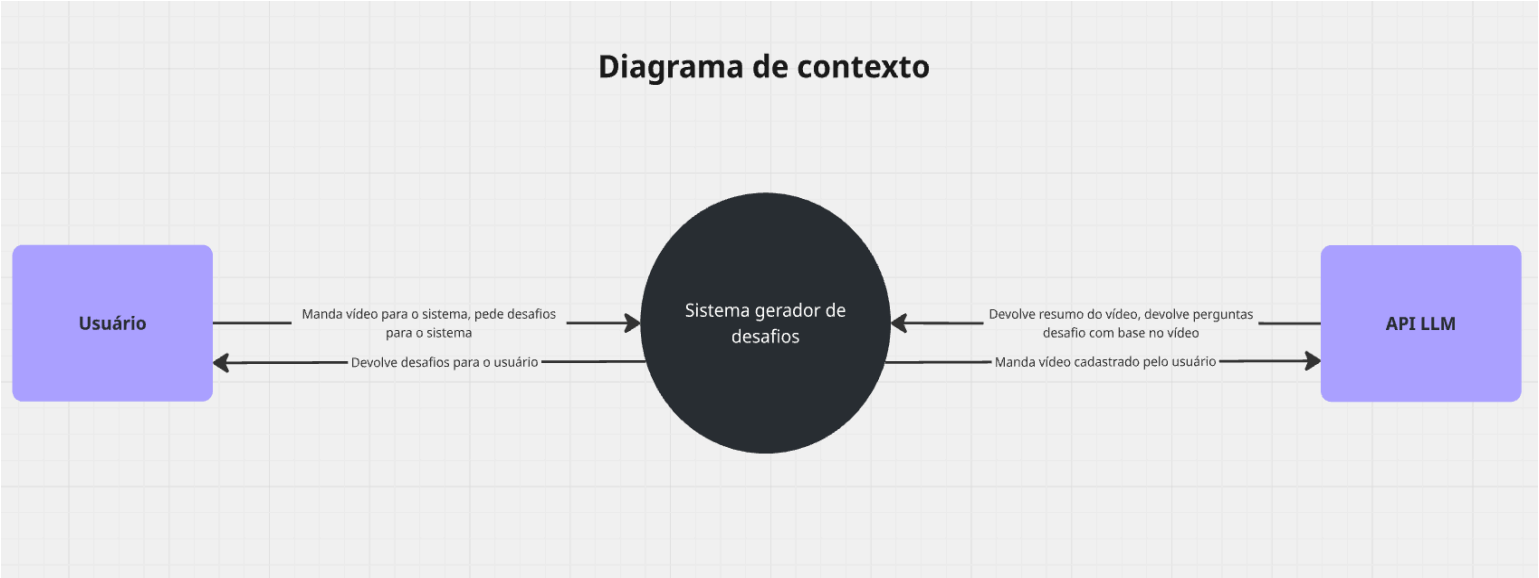

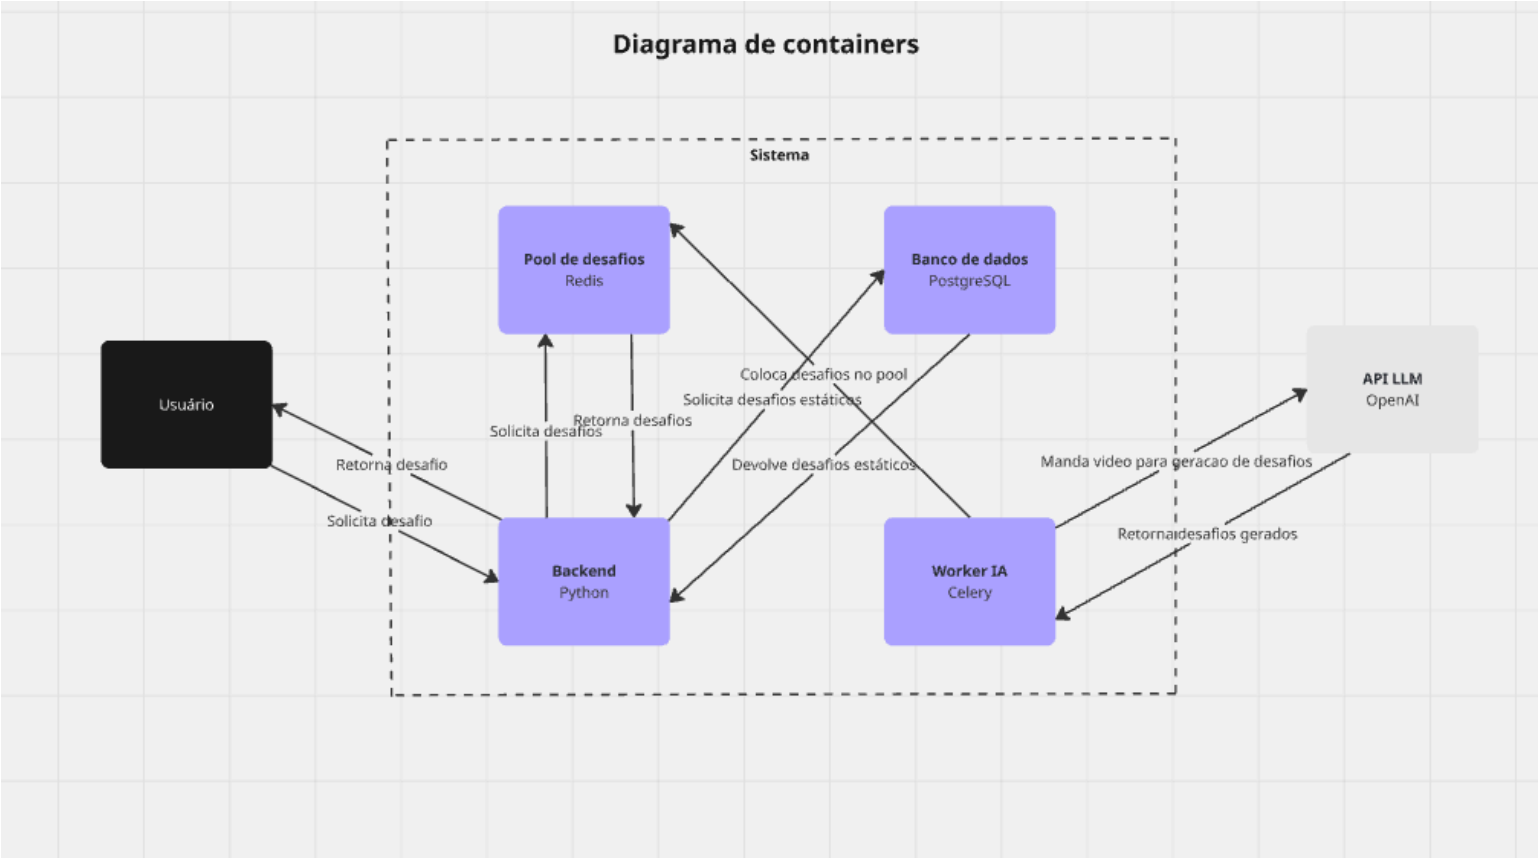

2. Diagrama C4

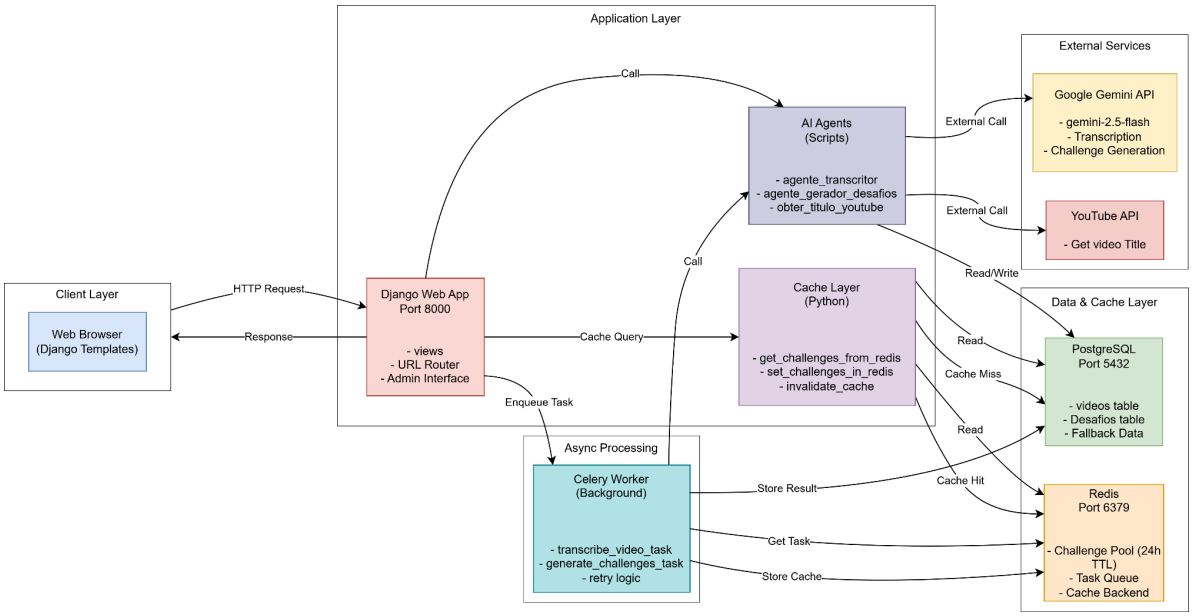

3. ADRs iniciais

ADR 01: Adoção de Processamento Assíncrono com Redis para o Pool.

Contexto: A geração de desafios pela IA (LLM) é um processo naturalmente lento e sujeito a oscilações de rede. Se o motor do jogo esperasse essa geração em tempo real, a experiência do usuário travaria.

Decisão: Optamos por implementar o processamento ASYNC acoplado ao padrão de Queues utilizando o Redis. O Redis atuará simultaneamente como corretor de mensagens (broker) para o worker e como cache em memória rápida para armazenar o pool de desafios gerados.

Consequências:

Positivo: O motor do jogo consegue consumir as perguntas do pool instantaneamente, pois o fluxo crítico é isolado da latência da IA.

Negativo (Trade-off): Adiciona complexidade à infraestrutura do projeto, exigindo o monitoramento de um serviço extra (Redis) e o gerenciamento de workers em background (Celery no Django).

ADR 02: Implementação de Circuit Breaker para a API da LLM

Contexto: O preenchimento do pool depende de uma API externa de IA (ex: GPT-4o-mini). APIs externas são pontos únicos de falha, podendo sofrer timeouts ou indisponibilidade total, o que comprometeria o worker.

Decisão: Adotamos o padrão Circuit Breaker para encapsular todas as requisições feitas à IA. Se a taxa de erros ou o tempo de resposta da OpenAI ultrapassar um limite tolerável, o disjuntor "abre", interrompendo novas requisições. Nesse momento, o sistema faz o fallback automático, consumindo perguntas de um banco de dados estático (PostgreSQL).

Consequências:

Positivo: Garante a resiliência contínua do sistema, evitando travamentos sistêmicos por lentidão de terceiros.

Negativo (Trade-off): Quando o disjuntor está aberto, o sistema perde sua característica principal: as perguntas servidas aos jogadores não terão contexto direto com os vídeos, diminuindo o valor temporário da solução.

4. Definição de stack tecnológico e justificativas

Linguagem Base e API: Python

- **Justificativa:** Python é a linguagem padrão da indústria para integrações com Inteligência Artificial e processamento de dados. Seu ecossistema rico e frameworks web robustos permitem o desenvolvimento ágil da API síncrona que atenderá o motor do jogo, além de facilitar a comunicação fluida com a API da LLM escolhida para a geração de desafios.

Processamento Assíncrono e Workers: Celery

- **Justificativa:** O núcleo desta POC exige que a geração de desafios seja desacoplada do fluxo crítico do usuário. O Celery atua como um

gerenciador de filas de tarefas distribuídas, permitindo que a geração baseada no conteúdo do vídeo ocorra de forma assíncrona em *background*. Isso garante que a latência da requisição à IA não impacte a experiência em tempo real do jogador.

Armazenamento em Memória e Mensageria (Pool): Redis

- **Justificativa:** O Redis foi escolhido por sua dupla função essencial nesta arquitetura. Primeiro, atua como o *Message Broker* (corretor de mensagens) exigido pelo Celery para gerenciar a fila de tarefas assíncronas. Segundo, opera como o *Cache/Pool* em memória principal, armazenando os desafios recém-gerados pela IA para garantir que a API os consuma e entregue ao motor do jogo com latência de milissegundos.

Armazenamento Persistente e Fallback: PostgreSQL

- **Justificativa:** Um banco de dados relacional maduro e altamente confiável para garantir a persistência segura das informações de longo prazo. O PostgreSQL assume um papel crítico de resiliência: ele armazenará o banco estático de perguntas pré-aprovadas, atuando como o sistema de *fallback* imediato caso o *pool* do Redis esvazie ou a API da IA fique indisponível.

5. Identificação dos padrões arquiteturais

SYNC vs ASYNC & Queues (Filas): O motor do jogo pede o desafio para a sua API e precisa de uma resposta na mesma hora (Fluxo Síncrono). No entanto, a geração do desafio pela IA demora, então ela é desacoplada do fluxo crítico operando como um pool assíncrono. O worker (ex: Celery) usa filas (Queues) no Redis para processar essas gerações em segundo plano sem travar o jogo.

Circuit Breaker (Disjuntor): Se a API da LLM cair ou ficar muito lenta, o Circuit Breaker é acionado. Imediatamente, seu sistema para de tentar

chamar a IA e aciona o fallback para o banco estático (Supabase). Isso atende exatamente ao requisito de testar a operação com a IA indisponível

Cache-Aside Pattern: A sua API atua consumindo o pool em tempo real. Ela tenta pegar o desafio no Redis (Cache). Se o Redis estiver vazio (esgotou o pool), ela vai buscar as perguntas pré-cadastradas no banco estático.

6. Divisão de responsabilidades entre os integrantes

Arthur Vieira - Desenvolvedor
Augusto Miguel - UI/UX
Carlos Eduardo - Testes
Igor Wanderley - Desenvolvedor
Joás Gomes - Documentação
Kalil Teotônio -Testes